



AquaFlow — краткая техническая документация

КосмоХакатон 2026 · кейс «Детектирование и оценка концентрации макропластика в морских акваториях»

Репозиторий: github.com/Serfetto/kosmofinal · полная версия: [docs/AquaFlow_TechDoc.pdf](#) (43 стр.) · 26.09.2026

AquaFlow — веб-сервис для специалиста по экологическому мониторингу. Пользователь выбирает акваторию и дату снимка Sentinel-2 и получает на карте зоны вероятного скопления плавающего мусора с маской качества снимка, полевые измерения из реестра кейса и модельную концентрацию в шт./км² с интервалом и статусом доверия. Результаты выгружаются в GeoJSON, CSV и PDF, сохранённый запрос повторяется с проверкой sha256. Дополнительно: прогноз дрейфа на 72 ч и маршрут судна к скоплениям.

F1 0,80

детектор на MARIDA test, IoU 0,67; у базовых порогов F1 0,02–0,04

935 → 220

строк реестра вошли в профили; у каждой строки — решение и причина

22,9 шт./км²

MAE профиля A на отложенной выборке (95% ДИ 19–27)

18 · 198

акваторий и обработанных снимков Sentinel-2

125 ✓

проверок pytest; метрики пересчитываются из предсказаний

Критерии хакатона: что выполнено и где это найти

Код	Критерий	Что сделано	Где найти и как проверить
01	Постановка ✓	Профили A (пластик ≥ 2 см) и B (весь мусор $\geq 2,5$ см), шт./км ² ; решение и причина по каждой из 935 строк; измерение и оценки различаются в данных и на карте.	<code>configs/profiles.yaml</code> , <code>data/field/selection.csv</code> ; <code>python -m pipeline.field prepare</code>
02	Достоверность ✓	C = N/A с ДИ; модели с формулами; отложенная выборка и вложенная CV против медианы и IDW; 80/95% интервалы; статусы применимости; перенос проверен.	карточка гекса → «Расчёт по шагам»; <code>python -m pipeline.verify</code>
03	Обоснованность зон ✓	6 классов (мусор, органика, суда, облака, вода, пена), фильтры против пены, блика, судов, облаков; ложные срабатывания по классам фона на MARIDA и MADOS.	«Сводка» → «Мусор, а не пена...», слой «Классы модели»; <code>data/eval/detector/</code>
04	Польза веб-карты ✓	Акватория и дата, 9 показателей, 11 слоёв, легенда с единицами, профилем, датами, источником и версией модели, фильтры, выгрузка.	<code>http://localhost:8000</code>
05	Защита ✓	Отчёт с методом, вкладом, решениями, ошибками и компромиссами; ответы на типовые вопросы; презентация к защите.	<code>docs/report.md</code> , полная версия §11
06	Доп. функции ✓	Дрейф 72 ч (проверен на парах снимков), дрейф без снимка, зоны схождения, маршрут судна, тренды, PDF-отчёт, сведение с измерениями.	инструменты «Дрейф», «Маршрут»; <code>data/eval/drift_check.json</code>
T1	Подготовка данных ✓	Отбор в коде по конфигу; реестр 251 пары «событие ↔ снимок»: сцена, сдвиг, след, маски качества, решение и причина.	<code>data/registry/pairs.csv</code> ; <code>pipeline.pairs build --offline</code>
T2	Детектирование ✓	P/R/F1/IoU на MARIDA test против двух базовых на той же выборке; порог зафиксирован до test; сохранены предсказания; проверка на MADOS.	<code>configs/detector.yaml</code> , <code>pred_test.npz</code> ; <code>python -m pipeline.verify</code>
T3	Концентрация ✓	Код шт./км ² ; контрольные примеры постановки в тестах; MAE, RMSE, лог-ошибка против базовых на тех же событиях; эталоны и предсказания в репозитории.	<code>tests/test_measure.py</code> , <code>data/eval/concentration/</code>
T4	Воспроизводимость ✓	Веса, выборки, эталоны, предсказания с sha256; <code>requirements.lock</code> ; составы выборок с ID; групповое разбиение, тесты на утечки.	<code>data/models/MANIFEST.json</code> , <code>data/splits/</code> ; <code>pytest -q</code>
T5	Интеграция ✓	Docker; сохранённый запрос с проверкой sha256; одни и те же числа в алгоритмах, интерфейсе и выгрузке; 404/422/503 вместо падений.	<code>/api/queries/0a0b3aaaf8f9/rerun</code> → <code>match: true</code>

Проверка за 5 минут


- `docker compose up -d --build` → `http://localhost:8000`: снимки, модели и метрики уже в репозитории.
- «Батуми — Кобулет», 05.06.2024 → клик по гексу: интервалы, статус, «Расчёт по шагам»; «Сводка» → «Сохранить» → «Повторить»: sha256 совпадает.
- `python -m pipeline.verify` — все метрики детектора и концентрации заново из сохранённых предсказаний.

Главная идея: снимок показывает, где искать, поле — сколько

При пикселе 10 м видны плотные скопления и полосы мусора, но не рассеянный мусор: 1000 предметов на км² по 0,01 м² — это ~10 м² на км², десятая часть одного пикселя. Поэтому три величины считаются отдельно и по-разному показаны на карте; площадь зоны детекции в шт./км² не переводится.

Величина	Откуда	Единица	На карте
Зона детекции	детектор XGBoost + фильтры по снимку Sentinel-2	площадь и покрытие, м²	красный контур
Полевое измерение	C = N / A по полосе учёта, 95% ДИ Гарвуда	шт./км²	полоса или кружок с белой обводкой
Модельная оценка	модель профиля, обученная на полевых учётах	шт./км², 80/95% интервал	заливка гекса; жёлтый пунктир — исследовательская оценка

Архитектура



pipeline/ заранее считает зоны, гексы, статусы и концентрацию для всех дат, сервис раздаёт готовые файлы из data/web/: снимки (~17 Гб) для запуска не нужны, выгрузка строится из тех же файлов, что и карта. Стек: Python 3.12, XGBoost, FastAPI, React, MapLibre GL, Docker.

Данные

Полевой реестр → профили

935 строк, 318 событий из 4 источников. Строка входит в профиль, только если совпадают тип записи, совокупность и протокол учёта.

Куда попали строки	Строк
A: S2 Саргассово море, пластик >2 см (обучение)	63
B: S4 Чёрное море, весь мусор >2,5 см (обучение)	33
B: S3 Северное море — только проверка переноса	41
C: S1 трал 5–50 см — без модели	83
исключены: категория, объектная запись, аэросъёмка	715

Учтено в коде: пустое ≠ 0; переход через полночь; дата без времени — интервал в сутки; 4 прерванные трансекты восстановлены сегментами из PANGAEA; C = N/A сверяется с опубликованной плотностью.


Реестр пар «событие ↔ снимок»

Сцены Sentinel-2 на дату ±1 сут., сдвиг интервалом, ярус синхронизации (≤3 ч / ≤18 ч), дрейфовый буфер, качество по всему следу события.

Итог по 220 событиям	
нет сцены Sentinel-2 (открытый океан, до 2015 г.) или только Landsat	185
сдвиг >18 ч — контекст	23
непригодные пиксели или блик в следе	3
принято (S4, тот же день)	9

Вывод: на 9 парах связи детекций с полевой плотностью нет (ρ = −0,23, p = 0,56) — концентрация в сервисе считается моделью по полевым данным.

Детектор скоплений



- **Нормализация фона** — главный шаг: из пикселя вычитается локальный спектр окружающей воды (блоки ~320 м) и прибавляется эталон воды MARIDA. Так уходят блик, дымка и разница атмосферной коррекции между MARIDA (ACOLITE) и нашими снимками (Sen2Cor).
- **Признаки:** 11 каналов, индексы FDI, FAI, NDVI, NDWI, PI, NDMI, текстура. **Обучение:** MARIDA train (694 патча), 15 классов сведены в 6 групп, неразмеченные пиксели не используются.
- **Фильтры:** NIR-аномалия сильнее синей (против пены), соседи с P > 0,3 (против шума), CFAR 5σ (против блика и ряби); буферы 100 м от облаков, 400 м от судов, 300 м ото льда; постоянные объекты по ряду снимков; на сценах со штормом ≥8 м/с или сильным бликом — только скопления от 4 пикселей.

MARIDA test: 15 сцен, 359 патчей, одна выборка	P	R	F1 (95% ДИ)	IoU
Пороги FDI и NDVI (базовый, подобраны на val)	0,011	0,580	0,022 (0,01–0,08)	0,011
Наивный Байес на FDI+NDVI, как Biermann et al. 2020 (базовый)	0,022	0,320	0,041 (0,01–0,29)	0,021
XGBoost, P ≥ 0,5	0,657	0,906	0,762 (0,67–0,86)	0,615
XGBoost + фильтры (в сервисе)	0,778	0,829	0,803 (0,72–0,88)	0,671

Сложный фон и границы

- Пороги не работают: мутная вода и саргассум дают FDI выше, чем мусор. Фильтры вдвое снижают ложные срабатывания ценой 8% попаданий.
- Главный источник ошибок на MARIDA — органика и плавник (26% пикселей класса).
- Регион, исключённый из обучения: F1 в среднем 0,52 (от 0 до 0,91).
- MADOS содержит MARIDA целиком; на 27 новых сценах F1 0,30: за мусор принимается 45% морской слизи и 38% медуз. Дообучение на MADOS пробовали в трёх вариантах — каждый теряет полосы мусора или ловит плёнки на наших снимках, модель сервиса оставили прежней.

Статус детекции гекса и зоны

обнаружено	есть детекция, прошедшая все фильтры
не обнаружено	детекций нет, видно ≥50% воды, нет блика, шторма и льда
недостаточно данных	облака, блик, шторм или лёд — отсутствие мусора подтвердить нельзя

Маска качества объясняет каждый исключённый пиксель: суша, нет данных, облако, тень, перистые, блик, лёд, судно, постоянный объект. Предсказания и эталон MARIDA test сохранены (pred_test.npz, ref_test.npz), галерея ошибок — gallery.png.



Керченский пролив, 03.06.2025, слой «Классы модели»: к какому классу модель отнесла каждый аномальный пиксель до порога и фильтров.

Концентрация в шт./км²

Профиль А — отрицательно-биномиальная GLM числа предметов со смещением log A (у S2 известны N и A):

$$C = \exp(3,889 + 0,290 \cdot z_{lat} + 0,421 \cdot z_{lon})$$

Профиль В — ридж-регрессия; признак — расстояние до берега d, км:


$$\ln(C + 1) = 5,336 - 0,372 \cdot (\ln(1 + d) - 4,154) / 1,051$$

Защита от утечек. Разбиение зафиксировано до экспериментов: события одного дня рейса, ближе 30 км и 3 сут. или с общей сценой — одна группа, группа целиком в обучении или в отложенной выборке (~20%). Признаки — только доступные при применении (координаты, расстояние до берега, ветер ERA5); 25 полей, производных от ответа, запрещены и проверяются тестом. Набор признаков выбирается по групповой CV из заранее заданных кандидатов.


Модель	Вложенная CV MAE	Отложенная MAE (95% ДИ)	Отложенная RMSE	Покрытие 80%-интервала
Профиль А: обучение 50 событий, отложено 13 (6 групп)				
NB-GLM (в сервисе)	38,4	22,9 (19–27)	26,6	77%
медиана / IDW (базовые)	37,1 / 36,3	24,8 / 20,6	28,5 / 25,2	—
Профиль В: обучение 26 событий, отложено 7 (3 группы)				
log-ridge (в сервисе)	183,7	230,9 (135–355)	285,4	71%
медиана / IDW (базовые)	208,1 / 178,5	132,3 / 198,7	172,4 / 236,4	—

- **Профиль А:** модель, медиана и IDW по MAE неразличимы (разность на отложенной –1,9, ДИ –5,7...+2,5). Половина ошибки неустранима: счётный шум трансект даёт MAE ≈ 12 шт./км² даже у идеальной модели.
- **Профиль В:** на вложенной CV модель не хуже базовых; на 7 отложенных событиях медиана точнее — у берега Батуми модель завышает, в открытом море занижает. Модель не подгонялась под отложенную выборку; значение всегда показывается с интервалом и статусом.
- **Интервалы 80% и 95% —** сплит-конформные по внефолдовым остаткам. **Сведение с полевыми измерениями** (кригинг остатков по расстоянию и давности) для профиля В снижает MAE на отложенной выборке с 231 до 185.
- **Перенос между морями** (обучение на Чёрном, проверка на Северном): модели завышают в 6–11 раз — перенос не работает.

Статус концентрации	Когда
модельная оценка	бассейн профиля, ≤60 км от обучающих событий, тот же сезон, признаки в диапазоне обучения
исследовательская оценка	бассейн тот же, но условие нарушено — причины перечислены (например, у побережья РФ полевых точек нет)
концентрация недоступна	другой бассейн или пресные воды



Сочи, 11.09.2026, показатель «Концентрация»: легенда с единиц, профилем, датами, источником и версией модели; жёлтый пунктир — исследовательская оценка; красные кружки — зоны детекции.



Батуми, 30.06.2024, показатель «Статус» и маска качества: облака и сильный блик — сложный случай, сцена разбирается как неудачная.

Веб-сервис и выгрузка

- **Сценарий:** акватория и дата → снимок и его качество (пролёт, облачность, видимая вода, блик, ветер) → зоны и показатель карты → карточка зоны, гекса или измерения → выгрузка.
- **Карта:** 9 показателей (концентрация, статус, качество, покрытие, среднее, устойчивость, тренд, скопление, прогноз), 11 слоёв, фильтры по статусам, инструменты «Данные кейса», «Участок», «Сравнить», «Дрейф», «Маршрут», «Методика».
- **Карточки:** у гекса — значение, интервалы, причины статуса и «Расчёт по шагам» с коэффициентами; у зоны — площадь отдельно от концентрации и «Почему это мусор» по каждому фильтру; у измерения — N, A, C, источник, флаги и строки реестра.
- **Выгрузка:** зоны и гексы в GeoJSON и CSV с единицей, профилем, интервалами, статусом, версией модели; PDF-отчёт с координатами зон. Одинаковый запрос — одинаковые байты (sha256 в заголовке); сохранённый запрос повторяется с проверкой match.
- **API:** 37 ручек, `/api/docs`; ошибки 404/422/503 с текстом по-русски, ни одна ручка не падает с 500 на мусорный ввод (тест).



Карточка гекса: интервалы, статус, расчёт по шагам, сведения с полосами DOORS.

Дополнительные функции

Прогноз дрейфа на 72 ч — лагранжев ансамбль по течениям SMOС и 1–3% ветра ERA5 с выбросом на берег; проверен без будущих данных на 7 парах соседних снимков: прогноз ближе к новым детекциям только в 2 парах (3,0 км против 1,4 км у «пятно на месте»), поэтому помечен справочным. **Дрейф без снимка** по реанализам Copernicus Marine для событий 2014–2016 гг. **Маршрут судна** к скоплениям с поправкой на дрейф к моменту прибытия. **Зоны схождения течений**, тренды и устойчивость по ряду снимков, сравнение двух участков. Прогнозы на карте всегда подписаны «Прогноз, не наблюдение».

Запуск и проверка

```
docker compose up -d --build # → http://localhost:8000; снимки и модели уже в репозитории
python -m pipeline.verify # секунды: sha256 весов и выборки, P/R/F1/IoU и MAE из предсказаний
python -m pipeline.reproduce --offline # сквозной пересчёт ~5 мин на CPU, 4 ГБ RAM
python -m pytest -q # 125 проверок: формулы, утечки, API, устойчивость
python -m pipeline.field explain S2:MSM41_litter-T18 # разбор одного измерения
python -m pipeline.concentration explain B 39.72 43.55 2025-07-18T08:10
```

Локально: Python 3.12 + `pip install -r requirements.lock`, Node.js 20+ для сборки интерфейса. Ключи не нужны; `.env` с бесплатным аккаунтом Copernicus Marine включает только дрейф без снимка. Полный пересчёт снимков — ~17 ГБ, ~45 мин на GPU.

Ограничения и развитие

- При 10 м видны скопления (≥ 20 –30% пикселя), а не отдельные предметы; слизь, медузы, плавник спектрально похожи на мусор — нужна проверка судном или дроном.
- Детектор обучен на тропической MARIDA; для Чёрного моря нужна локальная разметка.
- У побережья РФ полевых точек нет — там только исследовательская оценка.
- Разметить подготовленный набор (120 зон, 60 точек) по нашим водам.
- Совместные кампании «трансекта в день пролёта» — для калибровки «снимок → шт./км²».
- Второй регион для профиля A (S3, PANGAEA 890781); калибровка дрейфа.